Universidade Federal de Viçosa – Campus UFV-Florestal
Ciência da Computação – Mineração de dados e Mídias Sociais
Professor: Philipe de Freitas Melo
Aluno: Luana Tavares - Matrícula: 5364
Aluno: Marcus Eduardo Resende Melo - Matrícula: 5779

Análise de Interações e Sentimentos de Torcedores nos Clássicos entre Atlético-MG e Cruzeiro no YouTube.

Sumário

Introdução **3**

Parte 01 - Coleta de Dados Web ou de Redes Sociais **4**

2.1 Natureza e origem dos dados 4

2.2 Entidades e atributos 5

2.3 Volume e qualidade dos dados 6

2.4 Coletor, API e reprodutibilidade 7

2.5 Limitações dos dados 9

3. Parte 02 — Análise da Estrutura da Rede 10

3.1 Definição de nós e arestas — item (a) 10

3.2 Distribuição de grau e lei de potência — item (b) 10

3.3 Componentes conectados — item (c) 11

3.4 Clusterização — item (d) 11

3.5 Distâncias e diâmetro — item (e) 12

3.6 Medidas de centralidade — item (f) 12

3.7 Assortatividade — item (g) 13

3.8 Visualização da rede — item (h) 13

4. Análises complementares e enriquecimento dos dados 13

5. Interpretação integrada da questão de pesquisa 14

6. Considerações finais 15

Introdução

Plataformas de vídeo são ambientes de discussão esportiva. Nos clássicos entre Atlético-MG e Cruzeiro, comentários e respostas permitem observar reações ao placar, opiniões sobre jogadores e treinadores e conexões entre usuários. O projeto combina análise de conteúdo textual e análise estrutural de redes.

Questão de pesquisa: Como o resultado dos clássicos entre Atlético-MG e Cruzeiro está associado ao sentimento, aos assuntos discutidos e à estrutura das interações entre usuários no YouTube?

Hipótese: resultados desfavoráveis estão associados a maior negatividade e a maior atenção a desempenho, arbitragem e profissionais dos clubes. O desenho observacional permite verificar associações, não relações causais.

Parte 01 - Coleta de Dados Web ou de Redes Sociais

2.1 Natureza e origem dos dados

Este projeto foi baseado na coleta e análise de comentários públicos do YouTube. O conjunto de dados contempla os dez clássicos oficiais entre Atlético-MG e Cruzeiro presentes na base, disputados entre **9 de fevereiro de 2025 e 1º de setembro de 2026**, abrangendo partidas do Campeonato Mineiro, Campeonato Brasileiro e Copa do Brasil.

A coleta foi realizada em vídeos relacionados a cada confronto, selecionados conforme a data de publicação, a referência aos dois clubes e a relevância para os períodos de pré-jogo e pós-jogo. Ao todo, foram considerados **100 vídeos**, dos quais foram obtidos **58.910 registros**, incluindo comentários principais e respostas.

Os dados foram organizados em quatro grupos:

- informações das partidas, como data, competição, equipes, placar e resultado;
- metadados dos vídeos selecionados;
- comentários e respostas públicas, com conteúdo, data de publicação e estrutura de interação;
- bases auxiliares de jogadores, treinadores, integrantes da comissão técnica e membros da gestão vinculados a cada partida.

As informações sobre os confrontos foram consolidadas a partir de fontes verificáveis, registradas na própria base. Já os vídeos, comentários e respostas foram obtidos por meio da **YouTube Data API v3**. Essa organização permite analisar conjuntamente o conteúdo das manifestações, seu contexto esportivo e a rede de interações entre os usuários.

2.2 Entidades e atributos

O conjunto de dados foi estruturado em quatro entidades principais:

- **Partidas:** identificador do confronto, data e horário de início, competição, temporada, equipes mandante e visitante, placar, vencedor e resultado obtido por cada clube.
- **Vídeos:** identificador, título, descrição, canal de publicação, data e horário de publicação, confronto associado, período de publicação — pré-jogo ou pós-jogo —, número de visualizações, curtidas e comentários, além da consulta utilizada em sua seleção.
- **Comentários e respostas:** identificador do registro, vídeo e partida relacionados, identificador pseudonimizado e nome público do autor, texto original, data e horário de publicação e atualização, número de curtidas e indicação de resposta. Quando aplicável, também são registrados o comentário principal e seu autor. Posteriormente, cada registro é classificado como pré-jogo, durante o jogo ou pós-jogo, de acordo com seu horário de publicação em relação à partida.
- **Pessoas e entidades esportivas:** jogadores, treinadores, membros da comissão técnica e dirigentes vinculados ao contexto de cada confronto. Para essas entidades, são armazenados nome canônico, aliases, função, clube, participação na partida e resultado obtido pela respectiva equipe.

Essa estrutura possibilita relacionar cada manifestação ao vídeo de origem, à partida correspondente, ao momento em que foi publicada e às pessoas mencionadas, sustentando tanto a análise textual quanto a construção da rede de interações.

2.3 Volume e qualidade dos dados

Após as etapas de coleta, limpeza e integração, o conjunto de dados apresentou os seguintes indicadores:

Indicador	Valor obtido
Confrontos selecionados	10
Vídeos selecionados	100
Comentários principais	42.429
Respostas	16.481
Total de comentários e respostas tratados	58.910
Usuários distintos representados na rede	40.372
IDs de comentários duplicados	0
Referências inválidas a vídeos ou partidas	0
Textos vazios após a limpeza	1.294
Comentários com entidades reconhecidas	11.245
Menções pessoa-comentário	12.971

A avaliação de qualidade não identificou duplicidades nos IDs nem referências inválidas entre comentários, vídeos e partidas, indicando boa consistência estrutural da base. O tratamento textual incluiu normalização Unicode e de entidades HTML, padronização de caixa, remoção de URLs, menções, pontuação e símbolos gráficos, além da extração prévia de hashtags, URLs, menções e emojis para colunas específicas. Os textos originais foram preservados para fins de auditoria.

Cada comentário também foi classificado temporalmente como **pré-jogo**, **durante o jogo** ou **pós-jogo**, considerando seu horário de publicação em relação ao início e ao término estimado da partida.

Foram identificados 1.294 registros cujo texto ficou vazio após a normalização. Isso não significa necessariamente ausência de conteúdo no comentário original, pois alguns registros eram compostos exclusivamente por emojis, links, menções ou outros elementos removidos do texto analítico. Esses casos foram mantidos e sinalizados, mas exigem cautela ou exclusão explícita em análises lexicais e de sentimento.

2.4 Coletor, API e reprodutibilidade

O projeto inclui o código-fonte utilizado na identificação das partidas, seleção dos vídeos e coleta dos comentários. Os principais módulos são:

- src/matches/collect_matches.py: materializa o conjunto auditável das dez partidas e suas fontes;
- src/youtube/search_videos.py: pesquisa, filtra, classifica e seleciona os vídeos;
- src/youtube/collect_comments.py: coleta comentários principais e respostas;
- src/youtube/youtube_client.py: implementa autenticação, requisições, paginação e novas tentativas em falhas transitórias;
- config/settings.py: centraliza parâmetros, credenciais e caminhos dos arquivos.

A coleta utiliza a **YouTube Data API v3**. Na seleção dos vídeos, são realizadas chamadas aos recursos search.list e videos.list. O primeiro localiza vídeos a partir de consultas formadas pelos nomes dos clubes, data da partida, competição e termos relacionados ao pré e ao pós-jogo. O segundo complementa os registros com estatísticas e metadados, como visualizações, curtidas e quantidade de comentários.

A pesquisa utiliza, entre outros, os parâmetros type=video, order=relevance, maxResults=50, publishedAfter e publishedBefore. A janela de publicação compreende, por padrão, os três dias anteriores e posteriores a cada partida. Os resultados são recuperados em lotes de até 50 vídeos.

Para a coleta das interações, são utilizados:

- commentThreads.list, para obter os comentários principais de cada vídeo;
- comments.list, para recuperar de forma paginada todas as respostas disponíveis para cada comentário principal.

As requisições utilizam até 100 registros por página e percorrem o campo nextPageToken enquanto houver páginas disponíveis. A consulta separada das respostas é necessária porque aquelas incorporadas em commentThreads.list podem estar incompletas.

A seleção exige que o título ou a descrição faça referência aos dois clubes. Também são rejeitados resultados relacionados a videogames, categorias de base, futebol feminino, partidas históricas e vídeos no formato Shorts. Os candidatos restantes são ordenados por uma pontuação que considera referência direta ao clássico, termos associados ao confronto, visualizações e número de comentários. São mantidos, no máximo, cinco vídeos de pré-jogo e cinco de pós-jogo para cada partida. A consulta responsável por localizar cada vídeo é preservada no atributo search_query.

A coleta de comentários é incremental e retomável. Cada registro é gravado durante a execução, e o comment_id é utilizado para evitar duplicidades. Falhas transitórias recebem novas tentativas com espera exponencial, enquanto erros e vídeos com comentários

desativados são registrados no resumo da coleta. A autenticação pode ser realizada por chave da API ou OAuth 2.0, sem versionamento das credenciais.

Os parâmetros utilizados e o resumo da execução estão registrados em outputs/collection_summary.json. Os arquivos resultantes são armazenados em data/raw, enquanto os dados tratados ficam em data/processed. Como o conteúdo do YouTube pode mudar, uma nova execução pode produzir resultados diferentes do snapshot utilizado neste estudo.

Repositório de coleta e análise

2.5 Limitações dos dados

O conjunto analisado não constitui uma amostra probabilística ou representativa de todos os torcedores de Atlético-MG e Cruzeiro. Ele contempla apenas usuários que comentaram em vídeos selecionados do YouTube, estando sujeito a vieses relacionados aos canais escolhidos, aos critérios de seleção dos vídeos, aos mecanismos de recomendação da plataforma e à disposição individual dos usuários em participar das discussões.

O volume de comentários varia entre partidas, vídeos e períodos. O pós-jogo concentra consideravelmente mais registros que o pré-jogo, o que pode afetar comparações diretas. Além disso, vídeos diferentes atraem públicos distintos, e o nível de engajamento pode ser influenciado pela relevância da competição, pelo resultado, pela popularidade do canal e por acontecimentos específicos de cada confronto.

A preferência clubística dos autores não é conhecida com segurança e não deve ser inferida apenas pelo conteúdo das mensagens. Um mesmo usuário pode publicar vários comentários ou respostas, de modo que a quantidade de registros não corresponde necessariamente à quantidade de participantes independentes. Comentários também podem ser editados, removidos ou tornar-se indisponíveis após a coleta.

A classificação automática de sentimento apresenta limitações diante de sarcasmo, ironia, memes, provocações entre torcidas, erros ortográficos e expressões próprias do futebol. Da mesma forma, a identificação de temas e entidades depende das regras, palavras-chave e aliases cadastrados, podendo ocorrer omissões ou associações incorretas.

Por fim, as relações encontradas devem ser interpretadas como **padrões e associações observados no conjunto analisado**. O desenho observacional do estudo não permite estabelecer causalidade entre o resultado das partidas e o sentimento ou comportamento dos usuários, nem generalizar os resultados para as torcidas como um todo.

3. Parte 02 — Análise da Estrutura da Rede

3.1 Definição de nós e arestas — item (a)

A rede de interação foi construída a partir das respostas publicadas nos vídeos selecionados. Cada **nó** representa um usuário distinto do YouTube, identificado por um código pseudonimizado. Uma **aresta direcionada de A para B** indica que o usuário A respondeu a um comentário principal publicado pelo usuário B.

Indicador	Resultado
Usuários representados — nós	40.372
Arestas agregadas por partida e período	12.728
Respostas representadas pelos pesos	16.481
Autoarestas registradas inicialmente	527
Relações direcionadas distintas, sem autoarestas	12.179
Densidade da rede	0,00000747
Grau médio	0,603

As arestas são ponderadas: o peso representa o número de respostas enviadas entre o mesmo par de usuários. A estrutura original preserva separadamente as interações por partida e período. Para as métricas globais, relações repetidas entre o mesmo par são agregadas e as autoarestas são removidas. Algumas medidas, como clusterização, distâncias e assortatividade, utilizam a projeção não direcionada da rede.A baixa densidade e o grau médio inferior a uma conexão por usuário indicam que grande parte dos participantes publicou comentários sem estabelecer interações recorrentes com outros usuários.

3.2 Distribuição de grau e lei de potência — item (b)

Foram calculados os graus de entrada, saída e total, além de suas versões ponderadas. O grau de entrada representa quantos usuários distintos responderam a determinado participante, enquanto o grau de saída indica para quantos usuários ele enviou respostas. Nas medidas ponderadas, também é considerada a frequência dessas interações.

A distribuição apresenta forte concentração nos menores graus: muitos usuários possuem poucas conexões, enquanto um grupo reduzido alcança valores mais elevados. Esse comportamento produz uma cauda longa, característica comum em redes de interação digital.

Entretanto, a inspeção visual em escala logarítmica não é suficiente para comprovar uma distribuição de lei de potência. Essa conclusão exigiria ajuste estatístico, avaliação da qualidade do modelo e comparação com distribuições alternativas. Portanto, os resultados permitem afirmar apenas que a rede possui uma distribuição de grau heterogênea e com cauda longa.

3.3 Componentes conectados — item (c)

A rede apresenta **30.880 componentes fracamente conectados**, considerando as conexões sem observar sua direção. O maior componente fraco reúne **8.801 usuários**, correspondendo a aproximadamente **21,8% da rede**.

Também foram identificados **40.364 componentes fortemente conectados**, definidos como grupos nos quais existem caminhos direcionados de ida e volta entre os participantes. Como esse número é muito próximo do total de usuários, conclui-se que ciclos e relações direcionadas recíprocas são pouco frequentes.

Esses resultados evidenciam uma rede fragmentada, formada por muitos usuários isolados, pequenos grupos e poucas estruturas extensas de interação. O maior componente concentra uma parcela relevante dos participantes, mas não representa a maioria da rede.

3.4 Clusterização — item (d)

Medida	Resultado
Coeficiente médio de clusterização	0,0007528
Transitividade global	0,0015341

A clusterização foi calculada na projeção não direcionada da rede, após a remoção das autoarestas. Foram obtidos os seguintes valores:Os valores são muito próximos de zero, indicando baixa ocorrência de triângulos. Em outras palavras, quando um usuário interage com dois participantes, é raro que esses dois também apresentem uma relação entre si.

Esse comportamento difere de redes sociais baseadas em amizade, nas quais os contatos de uma pessoa frequentemente também estão conectados. No conjunto analisado, as interações assumem principalmente a forma de respostas pontuais, sem formação frequente de grupos densamente interligados.

3.5 Distâncias e diâmetro — item (e)

Como a rede é desconectada, não existem distâncias finitas entre todos os pares de usuários. Por esse motivo, a análise foi realizada no maior componente fracamente conectado, convertido em uma rede não direcionada.

Medida	Resultado
Distância média estimada	5,90
Maior caminho mínimo observado	17
Nós de origem amostrados	500

Para reduzir o custo computacional, os caminhos mínimos foram calculados a partir de uma amostra reprodutível de 500 nós de origem, utilizando a semente aleatória 42.A distância média indica que, dentro do maior componente, os usuários alcançáveis estão separados por aproximadamente seis conexões. O valor 17 corresponde à maior distância encontrada na amostra e não deve ser apresentado como o diâmetro exato de toda a rede.

3.6 Medidas de centralidade — item (f)

Foram calculadas três medidas complementares:

- **Centralidade de grau:** identifica usuários conectados diretamente a um número maior de participantes;
- **PageRank ponderado:** destaca usuários que recebem conexões de participantes estruturalmente relevantes, considerando também o peso das interações;
- **Centralidade de intermediação:** identifica usuários que aparecem com frequência nos menores caminhos entre diferentes regiões da rede.

Devido ao tamanho do grafo, a centralidade de intermediação foi estimada com uma amostra de 500 nós e semente 42. Os dez maiores valores de cada medida estão disponíveis em outputs/tables/centrality_top10.csv.

Os rankings utilizam pseudônimos locais, como “Usuário 001”, evitando a exposição direta dos participantes. Uma posição elevada nessas métricas representa destaque estrutural dentro do conjunto analisado, mas não comprova influência social fora dos vídeos ou da plataforma.

3.7 Assortatividade — item (g)

O coeficiente de assortatividade de grau foi calculado sobre a projeção não direcionada da rede. Essa medida corresponde à correlação de Pearson entre os graus dos nós localizados nas extremidades das arestas.

O valor obtido foi:

$$r \approx -0,229$$

O coeficiente negativo caracteriza uma tendência dissortativa: usuários com maior número de conexões tendem a interagir com participantes de menor grau. Esse padrão é compatível com discussões em que poucos usuários muito ativos respondem ou recebem respostas de muitos participantes pouco conectados.
O resultado representa uma tendência agregada da rede e não significa que todas as relações sigam esse comportamento. Os dados usados na comparação entre o grau dos usuários e o grau médio de seus vizinhos estão disponíveis em outputs/tables/assortativity_data.csv.

3.8 Visualização da rede — item (h)

Foi produzida uma visualização exploratória dos 60 usuários com maior grau ponderado: outputs/figures/network_top60.png
Na figura:

- o tamanho dos nós representa o grau ponderado;
- tons vermelhos indicam usuários que enviaram mais respostas do que receberam;
- tons azuis indicam usuários que receberam mais respostas do que enviaram;
- a espessura das arestas representa a frequência das respostas;
- as setas indicam a direção da interação.

Figura — Rede de respostas dos 60 usuários com maior grau ponderado.
Tamanho dos nós proporcional ao grau ponderado; cores representam a diferença entre respostas enviadas e recebidas; espessura das arestas proporcional à frequência da interação.
Fonte: elaboração própria.
A imagem representa apenas um recorte dos usuários mais ativos e não deve ser interpretada como uma visualização completa dos 40.372 participantes.

4. Análises complementares e enriquecimento dos dados

Além da análise estrutural, o projeto utiliza técnicas de mineração textual para investigar sentimento, temas, vocabulário e pessoas mencionadas nos comentários.

A classificação de sentimento emprega o modelo cardiffnlp/twitter-xlm-roberta-base-sentiment. Os temas são identificados por regras

multirrótulo, enquanto jogadores, treinadores, membros da comissão técnica e dirigentes são reconhecidos por nomes e aliases contextualizados para cada partida.

Resultado complementar	Valor
Negatividade no pré-jogo	31,1%
Negatividade no pós-jogo	50,0%
Negatividade após vitórias do Atlético-MG	49,1%
Negatividade após vitórias do Cruzeiro	46,5%
Negatividade após empates	65,9%
Positividade após empates	9,5%

As discussões envolvem principalmente rivalidade, jogadores, desempenho das equipes, resultado das partidas e arbitragem. Nuvens de palavras, frequências lexicais e uma rede de coocorrência entre pessoas complementam a interpretação.

A presença de uma entidade em um comentário negativo, contudo, não significa necessariamente que a crítica seja direcionada à pessoa mencionada. O sentimento representa o comentário completo e pode estar relacionado ao placar, à arbitragem ou a outro elemento do texto.

5. Interpretação integrada da questão de pesquisa

Os resultados sustentam parcialmente a hipótese inicial. O período pós-jogo apresenta maior volume de participação e proporção mais elevada de comentários negativos. Entretanto, vitórias não produzem automaticamente discussões predominantemente positivas. Os empates, por exemplo, apresentaram a maior proporção agregada de negatividade.

Estruturalmente, a rede é esparsa, fragmentada, pouco triangular e dissortativa. A atividade após as partidas aumenta principalmente pela entrada e participação pontual de muitos usuários, e não pela formação de uma comunidade global densamente conectada.

Assim, o resultado da partida está associado ao sentimento, aos temas discutidos e à intensidade das interações, mas não explica esses fenômenos isoladamente. A interpretação também deve considerar o contexto de cada confronto, os acontecimentos da partida, a competição, os vídeos selecionados e as características do público de cada canal.

6. Considerações finais

A análise dos comentários relacionados a dez clássicos entre Atlético-MG e Cruzeiro demonstra a utilidade da combinação entre mineração textual e análise de redes complexas para estudar discussões esportivas em plataformas digitais.

Foram observadas associações entre o contexto das partidas, o sentimento dos comentários, as pessoas mencionadas e a intensidade das interações. A rede apresenta participação ampla, mas baixa densidade, forte fragmentação e pouca formação de grupos interconectados. O pós-jogo concentra mais atividade e maior negatividade, embora o resultado esportivo não seja suficiente para explicar sozinho o comportamento das discussões.

Esses resultados devem ser interpretados considerando os critérios de seleção dos vídeos, as diferenças de volume entre partidas, os vieses de participação e as limitações dos métodos automáticos. O estudo identifica padrões no conjunto analisado, mas não permite generalizações para todos os torcedores nem conclusões causais sobre o efeito dos resultados esportivos.